

14.09.18 dl II

Методы оптимизации и  
регуляризации нейросетей

$$F(x) = \frac{1}{n} \sum_{i=1}^n f_i(x) \rightarrow \min_x, n \gg 1$$

Величина	Сложность
$f_i(x)$	$O(s)$
$\nabla f_i(x)$	$O(s)$
$F(x)$	$O(ns)$
$\nabla F(x)$	$O(ns)$

Необходимо вычислить  
методы оптимизации,  
не зависящие от числа  
слагаемых  $n$ .

$$SGD: \begin{cases} i_k \sim \text{Unif}(1 \dots n) \\ g_k = \nabla f_{i_k}(x_k) \\ x_{k+1} = x_k - \alpha_k g_k \end{cases}$$


$$\mathbb{E}_{i_k \sim \text{Unif}} g_k = \sum_{i=1}^n \frac{1}{n} \nabla f_i(x_k) = \nabla F(x_k)$$

SGD + mini-batches :

$$\begin{cases} I_k \sim \text{Unif}(1 \dots n) \\ g_k = \frac{1}{|I_k|} \sum_{i \in I_k} \nabla f_i(x_k) \\ x_{k+1} = x_k - \alpha_k g_k \end{cases}$$

Однмерная LR

$$F(w) = \frac{1}{n} \sum_{i=1}^n \underbrace{(y_i - wx_i)^2}_{f_i(w)} \rightarrow \min_w$$



III  $F$  - выпуклая,  $\in C^2 \Rightarrow \leq L^2 g$  на SCD верно


$$\mathbb{E} F(x_k) - F_{opt} \leq \frac{\underbrace{\|x_0 - x_{opt}\|^2}_{\leq R^2} + \sum_{i=0}^k \alpha_i^2 \underbrace{\mathbb{E} \|g_i\|^2}_{\leq G^2}}{2 \left( \sum_{i=0}^k \alpha_i \right)} \leq \frac{R^2 + G^2 \sum_{i=0}^k \alpha_i^2}{2 \left( \sum_{i=0}^k \alpha_i \right)}$$

$\alpha_i = h$

$$\frac{R^2 + G^2 h^2 (k+1)}{2h(k+1)} = \frac{R^2}{2h(k+1)} + \frac{G^2 h}{2} \xrightarrow{k \rightarrow \infty} \frac{G^2 h}{2}$$

область функционирования метода пропорциональна,  
матр. итерации и дисперсии стохастических град.

$$\mathbb{E} F(x_k) - F_{opt}$$



Достаточные условия  
сходимости

$$\begin{cases} \sum_i \alpha_i = \infty \\ \sum_i \alpha_i^2 < \infty \end{cases} \quad \left| \quad \frac{\sum_i \alpha_i^2}{\sum_i \alpha_i} \rightarrow 0 \right.$$

$$\alpha_i = \frac{h}{(i+1)^\tau}, \quad \tau \in (\frac{1}{2}, 1]$$

$\tau = 1$ ; сх-ть  $\sim O(\frac{1}{\ln k})$ ,  $\frac{1}{\ln k} = \varepsilon$ ,  $k = \exp(\varepsilon^{-2})$

очень медленно!

Для схемы  $\left( \frac{\sum_i \alpha_i^2}{\sum_i \alpha_i} \rightarrow 0 \right)$  можно брать  $\tau \in (0, \frac{1}{2}]$

Оптимальное  $\tau_{opt} = \frac{1}{2}$  и сх-ть  $\sim O(\frac{1}{\sqrt{k}}) = \tilde{O}(\frac{1}{\sqrt{k}})$

GD можно справиться

с вытянутыми эллипсами,

что особенно важно для

нейросетевых эл-ов с широкими плато




$$GD: x_{k+1} = x_k - \alpha_k \nabla F(x_k)$$

$$Newton: x_{k+1} = x_k - \alpha_k [\nabla^2 F(x_k)]^{-1} \nabla F(x_k)$$

SGD + momentum

$$x_{k+1} = x_k - \alpha_k g_k + \beta_k (x_k - x_{k-1}), \beta_k \in (0, 1)$$




Экспоненциальное сглаживание на историю шагов, инерция  
 $-g_k \uparrow (x_k - x_{k-1})$

Ada Grad

$$\begin{cases} x_{k+1,i} = x_{k,i} - \alpha_k \frac{g_{k,i}}{\sqrt{v_{k,i} + \epsilon}} \\ v_{k,i} = \sum_{j=0}^k g_{j,i}^2 \end{cases}$$

уменьшает шаг для больших град., увеличивает для мал.



нормирование на квадраты

RMSprop

$$\begin{cases} x_{k+1,i} = x_{k,i} - \alpha_k \frac{g_{k,i}}{\sqrt{v_{k,i} + \epsilon}} \\ v_{k,i} = \beta_k v_{k-1,i} + (1 - \beta_k) g_{k,i}^2 \end{cases}$$

ADAM

$$\begin{cases} x_{k+1,i} = x_{k,i} - \alpha_k \frac{\mu_{k,i}}{\sqrt{v_{k,i} + \epsilon}} \\ \mu_{k,i} = \delta_k \mu_{k-1,i} + (1 - \delta_k) g_{k,i} \\ v_{k,i} = \beta_k v_{k-1,i} + (1 - \beta_k) g_{k,i}^2 \end{cases}$$



$$v_{0,i} = 0$$

$$v_{1,i} = (1-\beta) g_{1,i}^2$$

$$v_{2,i} = \beta(1-\beta) g_{1,i}^2 + (1-\beta) g_{2,i}^2$$

$$v_{k,i} = \sum_{j=2}^k (1-\beta) \beta^{k-j} g_{j,i}^2 \in g_{0,i}^2$$

$$\mathbb{E} v_{k,i} = \sum_{j=2}^k (1-\beta) \beta^{k-j} \mathbb{E} g_{j,i}^2 \approx \mathbb{E} g_{0,i}^2 (1-\beta) \frac{1-\beta^k}{1-\beta} = (1-\beta^k) \mathbb{E} g_{0,i}^2$$


возникнет смещение на первых итерациях метода, необходима коррекция!

$$\hat{\mu}_{k,i} = \frac{\mu_{k,i}}{1-\beta^k}, \quad \hat{v}_{k,i} = \frac{v_{k,i}}{1-\beta^k}$$

## ИРегуляризация

Обычные  $l_1, l_2$  не работают, поскольку нормы градиента различны на разных уровнях сети.

## Drop Out




$$z = wx + b$$

$$a = g(z)$$

$$y_i \sim \text{Bern}(p) : \begin{cases} 0 & 1-p \\ 1 & p \end{cases}$$

$$a^{DO} = y \odot a$$



используем случайный шум для регуляризации

разрушаем координатную весов на вложенных слоях сети


$$\mathbb{E}_{y \sim \text{Bern}} a^{00} = (1-p)a$$

необходимо корректировать выход сети на тесте,

$$\text{иначе } a^{00} = \frac{1}{1-p} y \text{ or } a \Rightarrow \mathbb{E}_{y \sim \text{Bern}} a^{00} = a$$

Регулирование нормы градиента  
на внутренних слоях сети

Batch Normalization



$$\{x_{ij}\}_{i=2}^{N_{\text{batch}}} \rightarrow \boxed{\text{BN}} \rightarrow \{y_{ij}\}_{i=2}^{N_{\text{batch}}}$$

$\uparrow$   
 $\{\sigma_j, \beta_j\}$

$$\mu_j = \sum_{i=2}^{N_{\text{batch}}} x_{ij}, \quad \sigma_j^2 = \frac{1}{N_{\text{batch}}} \sum_{i=2}^{N_{\text{batch}}} (x_{ij} - \mu_j)^2$$

$$y_{ij} = \sigma_j \frac{x_{ij} - \mu_j}{\sigma_j + \epsilon} + \beta_j$$

вставляют после линейности  
и до нелинейности

для теста делается экспоненциальное сгла-  
живание для  $\mu$  и  $\sigma$  по всем мини-батчам,  
и эти скользящие  $\hat{\mu}$  и  $\hat{\sigma}$  используются для  
прогноза, иначе можно посчитать  $\hat{\mu}$ ,  $\hat{\sigma}$  по  
всей выборке за дополнительную эпоху  
после обучения.